

	Pós-graduação Disciplina – Inteligência Artificial para Ciência de Dados - Turma B - 0726 Projeto ABP (Aprendizagem Baseada em Projetos): Do Dado ao Valor — Documento de Entrega Final
--	---

Modelo de Projeto

Curso: Pós-Graduação em Ciência de Dados e Inteligência Artificial

Dataset Escolhido pela Equipe: Inserir o nome do dataset aqui - Ex: Wine Quality, House Prices, etc.

Link do Repositório Central (GitHub / Drive): Inserir link público e acessível aqui

Identificação da Equipe e Governança Técnica

Instruções para a Equipe: Preencha os nomes completos dos 6 integrantes e confirme a divisão das duplas responsáveis por liderar cada uma das fases principais de entrega.

Divisão de Trabalho	Nome Completo do Discente	Matrícula / Registro Acadêmico
Dupla A <i>(Líderes Fase 1)</i>	Discente 1: Discente 2:	
Dupla B <i>(Líderes Fase 2)</i>	Discente 3: Discente 4:	
Dupla C <i>(Líderes Fase 3)</i>	Discente 5: Discente 6:	

1. Fase 1: Preparação de Dados & Setup Estrutural (Foco: Dupla A)

1.1 Tratamento de Dados e Engenharia Base

Detalhe como a equipe tratou dados nulos (se houve aplicação de média, mediana, modelagem ou descarte) e como foram removidas as duplicatas. Descreva qual critério foi adotado para mapear, balancear ou ajustar a variável alvo (Target).

1.2 Estratégia de Isolamento e Escala

Apresente a proporção do Split de dados efetuado (ex: 80% treino / 20% teste). Explique qual transformador de escala foi adotado (ex: StandardScaler ou MinMaxScaler) e comprove os

mecanismos utilizados para garantir que ele tenha sido ajustado estritamente no conjunto de treino, mitigando o vazamento de dados (Data Leakage).

2. Fase 2: Análise Exploratória & Engenharia de Modelagem (Foco: Dupla B)

2.1 Gráficos Analíticos Essenciais (Máximo 3)

Insira aqui até 3 capturas de tela dos gráficos analíticos mais relevantes gerados no ambiente de desenvolvimento (ex: Mapa de calor de correlação, Boxplot explicativo ou Distribuição das classes). Abaixo de cada imagem, inclua um parágrafo dissertativo explicando o insight estatístico extraído.]

2.2 Resultados e Tabela Comparativa de Desempenho

O processo de treinamento utilizou o algoritmo definido como linha de base técnica (baseline) confrontado diretamente com o modelo preditivo avançado eleito pela equipe.

Modelo Avaliado	Acurácia de Teste	F1-Score de Teste	Justificativa de Seleção / Comportamento Detalhado
Baseline (Ex: Regressão Logística)	[0.0000]	[0.0000]	[Inserir breve análise técnica sobre o desempenho da linha de base e suas limitações estruturais.]
Avançado (Ex: Random Forest / XGBoost)	[0.0000]	[0.0000]	[Explicar matematicamente ou por arquitetura por que este modelo superou ou não o baseline técnico.]

Confirme o nome do arquivo binário final gerado e salvo pela equipe (ex: melhor_modelo.joblib, modelo.pkl) para fins de auditoria de código e reprodutibilidade.

3. Fase 3: Visão de Negócio, ROI & Governança de Dados (Foco: Dupla C)

3.1 Comunicação Visual (Link do Dashboard)

Insira o link público e acessível do painel interativo ou aplicação estruturada pela equipe (Looker Studio, Power BI, Streamlit ou correspondente) e resuma a experiência de UX e a arquitetura de informação proposta para o usuário final.

3.2 Retorno sobre o Investimento (ROI) Estimado

Explique de forma qualitativa e quantitativa como o uso prático desse modelo preditivo reduz custos operacionais, otimiza o tempo de triagem, mitiga riscos ou previne perdas financeiras dentro do cenário do problema analisado.

3.3 Riscos, Ética e Adequação à LGPD

Avalie criticamente o impacto institucional se o modelo gerar um volume elevado de falsos positivos ou falsos negativos. Identifique se há dados pessoais sensíveis envolvidos e quais salvaguardas

técnicas, de anonimização ou de consentimento (estritamente alinhadas à LGPD) devem ser implementadas no sistema de produção.

4. Cronograma de Execução e Próximos Passos

Nota de Planejamento: Esta seção serve como o mapa diretivo para o desenvolvimento futuro do projeto.

Fase do Projeto	Atividade Principal	Dupla Responsável	Período Estimado	Status Atual
1	Limpeza, Engenharia de Atributos e Split de Treino/Teste	Dupla A	[Data Inicial] a [Data Final]	[Planejado / Em Execução]
2	Análise Exploratória, Treinamento e Validação dos Modelos	Dupla B	[Data Inicial] a [Data Final]	[Planejado]
3	Construção do Dashboard, Análise de ROI e Relatório Final	Dupla C	[Data Inicial] a [Data Final]	[Planejado]

5. Gestão de Riscos Aplicadas a projetos de IA para Ciência de Dados

5.1 Introdução

Diferente do desenvolvimento de software tradicional, projetos de IA e Ciência de Dados possuem uma natureza **experimental e probabilística**. Isso significa que os riscos não são apenas de prazo ou orçamento, mas também de os dados não responderem à pergunta de negócio ou do modelo perder performance ao longo do tempo.

Neste sentido, a natureza de um projeto de Inteligência Artificial e Ciência de Dados requer uma abordagem que combine a previsibilidade do gerenciamento de projetos tradicional com a flexibilidade do ciclo de vida de dados.

Para tanto, a gestão de riscos desta proposta foi estruturada sob a convergência das melhores práticas do **Guia PMBOK® (PMI)** para controle de restrições de escopo e cronograma, da norma **ISO 31000** para governança integrada, e do framework **CRISP-DM** combinado ao **NIST AI RMF**, mitigando as incertezas técnicas de dados e a robustez estatística dos modelos preditivos do início à implantação.

5.2 Gerenciamento de Riscos e Incertezas

Para fins deeste projeto, a gestão de riscos foi divida em **4 categorias principais**:

a. Riscos de Dados (A base de tudo)

- **Volume insuficiente:** Não ter dados bastantes para treinar o algoritmo.
- **Baixa qualidade (Ruído):** Dados faltantes, desatualizados ou inconsistentes.
- **Acesso e privacidade:** Bloqueios por conformidade legal (como a LGPD) ou falta de integração entre sistemas.

- *Mitigação básica:* Realizar uma etapa prévia de Auditoria de Dados (Data Assessment) antes do início do desenvolvimento.

b. Riscos de Modelagem e Técnicos

- **Overfitting / Superajuste:** O modelo funciona bem no treino, mas falha tragicamente com dados novos do mundo real.
- **Inviabilidade matemática:** O padrão buscado simplesmente não existe ou não pode ser previsto de forma confiável com as variáveis atuais.
- *Mitigação básica:* Adotar validação cruzada rigorosa e definir uma "Métrica Base" (Baseline) simples para comparar o ganho real da IA.

c. Riscos de Implantação e Operação (MLOps)

- **Degradação do Modelo (Data Drift):** O comportamento dos usuários ou o mercado mudam, e o modelo começa a errar (ex: comportamento pré e pós-pandemia).
- **Infraestrutura:** Alto custo computacional para processar o modelo em tempo real.
- *Mitigação básica:* Desenhar uma arquitetura de monitoramento contínuo com alertas de perda de acurácia para retreinamento automático.

d. Riscos de Negócio e Adoção

- **Falta de alinhamento:** O modelo atinge 95% de acurácia matemática, mas resolve o problema errado do ponto de vista do negócio.
- **Resistência dos usuários:** A equipe de ponta não confia nas previsões da "caixa-preta" e ignora a ferramenta.
- *Mitigação básica:* Incluir especialistas do negócio no desenho do projeto e aplicar técnicas de IA Explicável (XAI) para justificar as decisões do modelo.

5.3 Matriz de Riscos

Com base no arcabouço supracitado, elaborou-se a matriz abaixo, para identificar as incertezas.

Categoria	Descrição do Risco	Probabilidade	Impacto	Ação Mitigadora (Prevenção / Contingência)
Dados	Dados insuficientes, ruidosos ou com muitos valores faltantes para o treino do modelo.	Média	Alto	Realizar um <i>Data Assessment</i> (auditoria) nas duas primeiras semanas. Se necessário, aplicar técnicas de imputação de dados ou engenharia de atributos.
Dados	Restrições de segurança ou LGPD bloquearem o acesso às bases necessárias.	Baixa	Alto	Envolver a equipe jurídica/segurança da informação logo no <i>kick-off</i> do projeto para garantir a anonimização e os acessos

Categoria	Descrição do Risco	Probabilidade	Impacto	Ação Mitigadora (Prevenção / Contingência)
				formais.
Técnico	O modelo sofrer <i>overfitting</i> (superajuste), performando bem no treino e mal em produção.	Média	Alto	Utilizar técnicas rigorosas de validação cruzada (<i>Cross-Validation</i>) e separar estritamente uma base de teste que nunca foi vista pelo modelo.
Técnico	Inviabilidade matemática (as variáveis disponíveis não explicam ou não conseguem prever o alvo).	Baixa	Muito Alto	Criar um modelo de <i>baseline</i> (regra simples ou regressão linear básica) na fase inicial para validar se há sinal estatístico nos dados.
Operação	O modelo perder acurácia ao longo do tempo devido à mudança no comportamento dos dados (<i>Data Drift</i>).	Alta	Médio	Desenhar uma arquitetura de MLOps que preveja o monitoramento contínuo das métricas do modelo e gatilhos para retreinamento automático.
Negócio	Falta de adesão dos usuários finais por não confiarem ou não entenderem as decisões da IA.	Média	Alto	Adotar abordagens de IA Explicável (XAI), utilizando bibliotecas como SHAP ou LIME para justificar as previsões do modelo de forma visual e simples.

Obs:

- 1) Prezados discentes, parabéns por chegarem até este ponto e ter aceito este grande desafio!
- 2) Continue a crescer na sua vida acadêmica e profissional.
- 3) Façam, as adaptações necessárias, respeitando as boas práticas.

Prof. Me Francisco Neto