

	Pós-graduação Disciplina – Inteligência Artificial para Ciência de Dados - Turma B - 0726 Sistematização Projeto ABP (Aprendizagem Baseada em Projetos): Do Dado ao Valor — Documento de Entrega Final
--	--

Desafio Prático: Miniprojeto de IA e Ciência de Dados (Avaliação)

1. Introdução

Prezados discentes, individualmente ou em grupo de até **6** pessoas, deverá (ão) desenvolver um **modelo preditivo** ao longo do curso, seguindo o fluxo prático: *Aquisição* → *Preparação* → *Análise Exploratória* → *Modelagem Preditiva* → *Visualização* → *Discussão do Resultado*.

2. Organização dos Grupos

- Atividade **individual** ou em **grupo de até 06 (seis)** discentes (componentes).
- Os grupos devem informar os **nomes dos membros** no Fórum “Fale com o Professor” (abrir um tópico e listar os nomes).
- Mantenha um repositório (zip ou link público) com **dados, notebook(s), código e gráficos**.

3. Entregas & Critérios da Avaliação

Serão **6 fases** com entregas próprias, descritas na forma abaixo.

Fase	Critérios (síntese)	Peso
0) Projeto de IA + CD	Planejamento de um pequeno projeto O bom vernáculo da língua portuguesa, coerência na solução apresentada, ferramentas e os fundamentos de IA e Ciência de Dados, apresentação e organização do trabalho, utilização de literatura de referência (autores, referências) e de documentação de boas práticas (ABNT, ISO, IEEE, PMBOK, SWEBOK, etc), riscos, cronograma.	10%
1) Aquisição do Dado	Justificativa do dataset e modalidade; formato; licenças; amostra; dicionário/descrição.	10%
2) Preparação do Dado	Limpeza, padronização, splits, tratamento de outliers/nulos, normalização/encoding, documentação.	15%
3) Análise Exploratória	Estatísticas, visualizações, correlações, hipóteses, achados acionáveis.	15%
4) Modelagem Preditiva	Baseline, ajustes, validação, métricas, comparações e justificativas.	15%
5) Visualização	Dashboard/relatório visual claro e fiel aos dados e às métricas (storytelling).	15%
6) Discussão do Resultado	Relatório crítico: insights, limitações, riscos, ética/LGPD, ROI e próximos passos.	20%

As entregas devem ser reprodutíveis (dados de exemplo ou link, código/notebook, versões, requirements.txt e seed fixo).

4. Descrição das Fases Propostas ABP

0) Desafio Prático: Miniprojeto de IA e Ciência de Dados

Como desdobramento das reflexões debatidas nas webaulas, referências bibliográficas, propõe-se aos discentes o desenvolvimento de um **Miniprojeto Prático Aplicado**, para compor a **nota final da avaliação na Disciplina (40%)**.

O objetivo é transpor os conceitos teóricos de curadoria, modelagem e inteligência analítica para um cenário real e enxuto. Os discentes deverão escolher uma base de dados propostas pelo professor, ou ainda, pública ou corporativa e aplicar o pipeline de Ciência de Dados focado na extração real de valor para o negócio, para atender os objetivos das demais fases propostas.

Estrutura Esperada do Projeto, conforme modelo disponibilizado, e considerar, ainda:

1. **Curadoria e Tratamento (Engenharia):** Identificação da base, tratamento de dados ausentes ou ruidosos e aplicação de técnicas estatísticas para redução de viés (BRUCE; BRUCE, 2019; FERREIRA et al., 2021).
2. **Modelagem Analítica:** Implementação de um script em Python para análise preditiva/Machine Learning (NETTO; MACIEL, 2021) ou uma modelagem matemática/otimização via planilhas (RAGSDALE, 2014).
3. **Entrega de Valor (BI):** Construção de um relatório descritivo focado em tomada de decisão estratégica para a gestão (SHARDA; DELEN; TURBAN, 2019; FOREMAN, 2016).
4. **Formato de Entrega:** O projeto deverá ser enviado em arquivo único, integrante do todo (elaborado com 6–10 páginas) com linguagem clara, executiva e técnica. A sua parte complementar, ao final será o **Relatório** da execução do Projeto (contendo o código documentado ou planilha de modelagem e um relatório executivo de até 6-10 páginas com as decisões de negócio – maiores detalhes na fase correta).

Esta é a oportunidade de consolidar a prática da engenharia analítica e destacar-se na fronteira tecnológica global

1) 📁 Aquisição do Dado (Hugging Face Datasets)

Escolha um dataset no [Hugging Face](https://huggingface.co/datasets) (<https://huggingface.co/datasets>), kaggle (<https://www.kaggle.com/datasets>), e/ou outro local que os dados sejam públicos e acessíveis, definindo **Modalidade** e **Formato**:

Modalidades:

3D • Audio • Document • Geospatial • Image • Tabular • Text • Time-series • Video, etc.

Formatos:

json • csv • parquet • imagefolder • soundfolder • webdataset • text • arrow, etc.

Entrega: link do dataset, amostra (até 1% ou 5k linhas/imagens), licença, dicionário de dados e justificativa do problema (classificação, regressão, etc).

2) 🛠️ Preparação do Dado

- **Qualidade:** remover duplicados; tratar nulos (drop/imputação: média/mediana/KNN); corrigir tipos e escalas.
- **Outliers:** IQR ou Z-score; decidir capar/corrigir/justificar manutenção.
- **Normalização/Padronização:** MinMaxScaler ou StandardScaler (conforme algoritmo).

- **Encoding:** one-hot para categóricas; target encoding (com cuidado a leakage).
- **Balanceamento:** avaliar distribuição de classes; usar `class_weight`, SMOTE (quando couber) ou undersampling.
- **Splits reprodutíveis:** train/valid/test (ex.: 70/15/15), `random_state` fixo.
- **Pipeline:** preferir `sklearn.Pipeline/ColumnTransformer` para evitar vazamento.

Entrega: notebook com pré-processamento, `requirements.txt` e artefatos limpos (ex.: `parquet`).

3) **Análise Exploratória (EDA)**

- **Estatísticas:** `describe`/percentis; missing map; cardinalidade das categóricas.
- **Gráficos:** histogramas, boxplots, barras, dispersão, matriz de correlação/heatmap; séries temporais (linha).
- **Relações:** correlação de Pearson/Spearman; análise por grupos; interações relevantes.
- **Ferramentas de apoio (opcional):** `ydata-profiling` (ex-`pandas-profiling`) ou `sweetviz`.
- **Hipóteses:** levante perguntas e respostas guiadas pelos dados (o que mais impacta a variável-alvo?).

Entrega: notebook (ou relatório curto) com gráficos e insights acionáveis.

4) **Modelagem Preditiva**

- **Baseline:** um modelo simples (Regressão Linear/Logística, Árvore, Naive) para referência.
- **Modelos candidatos:** tree-based (`RandomForest`, `XGBoost/LightGBM`), SVM, Redes (conforme modalidade).
- **Validação:** k-fold/estratificada; time-series split quando aplicável.
- **Métricas:** Classificação (Accuracy, F1, ROC-AUC); Regressão (MAE, RMSE, R^2). Justifique a métrica principal.
- **Tuning:** `GridSearchCV/RandomizedSearchCV`; evite overfitting; registre hiperparâmetros.
- **Interpretação:** `feature_importances_`, SHAP/LIME (quando possível).
- **Caso não realize a etapa, apenas descrever em poucas palavras o que pode ser feito com esses dados.**

Ferramentas gratuitas (online): [Google Colab](#), [Kaggle Notebooks](#), [scikit-learn](#), [Weka](#), [Hugging Face AutoTrain](#) (quando aplicável).

Entrega: notebook do treino/validação, tabela de métricas, melhor modelo salvo (ex.: `joblib`).

5) **Visualização (Comunicação de Resultados)**

- **Dashboard/Story:** selecione 4–8 gráficos essenciais (métricas do modelo, distribuição da predição, erros, variáveis-chave).
- **Boas práticas:** títulos descritivos, unidades, legendas claras, cores consistentes, acessibilidade.
- **Indicadores:** métrica principal + faixa de desempenho; comparação com baseline.

Ferramentas gratuitas (online): [Looker Studio](#), [Tableau Public](#), [Flourish](#), [Plotly Chart Studio](#), [Observable](#).

Entrega: link público do dashboard ou PDF exportado + 1 parágrafo de leitura analítica para cada visual.

6) 🧠 Discussão do Resultado (Relatório Crítico)

Elabore um **relatório** (6–10 páginas) com linguagem clara, executiva e técnica. Inclua:

- **Problema & Valor:** contexto, pergunta de negócio, impacto esperado.
- **Método:** resumo das etapas (dados, preparação, EDA, modelos, validação, métricas).
- **Resultados:** comparação com baseline, melhores modelos, interpretação (variáveis-chave, SHAP/LIME se houver).
- **Confiabilidade & Limitações:** qualidade de dados, viés, overfitting, generalização.
- **Riscos & Ética:** privacidade (LGPD), segurança, vieses algorítmicos, mitigação.
- **Recomendações & ROI:** como usar o modelo, ganhos potenciais, custos, próximos passos (dados extras, novas features, re-treino).

Entrega: PDF do relatório + anexos (links/notebooks/dashboards).

📌 Observações Importantes

- Defina **seed** (random_state) e registre versões (pip freeze > requirements.txt).
- Evite **data leakage** (aplique transformações dentro do pipeline/apenas no treino).
- Mantenha rastreabilidade: fontes, data/hora de coleta, licenças do dataset Hugging Face.
- Entregas podem ser feitas por link (Colab/Kaggle/Looker/Tableau Public) + ZIP com artefatos.

📄 Versão Teórica Alternativa

- Para quem optar, existe uma versão teórica alternativa, que terá mesma pontuação, mas poderá ser feita na forma de uma pesquisa acadêmica. Mas deverá ter, de igual modo, o Projeto.

1) Introdução e Justificativa (Aquisição do Dado)

- Apresente um **tema de interesse** (ex.: habitação, saúde, educação, marketing, transporte, clima etc.).
- Contextualize **por que os dados são relevantes** nesse domínio.
- Cite **bases públicas** disponíveis (ex.: IBGE, Kaggle, Hugging Face, INEP, OMS).

2) Revisão Teórica (Preparação do Dado)

- Pesquise e descreva **técnicas de limpeza e preparação de dados**:
 - tratamento de nulos e outliers, normalização, encoding, splits reprodutíveis.
- Aborde as **boas práticas** (documentação, versionamento, pipelines reprodutíveis).

3) Análise Exploratória e Estatística Descritiva (EDA)

- Explique o **propósito da EDA**: identificar padrões, correlações e insights.
- Mostre **como interpretar gráficos e medidas** (média, mediana, desvio padrão, correlação de Pearson etc.).
- Inclua **exemplos ilustrativos** (podem ser figuras, tabelas, ou prints explicativos).
- Discuta **como a EDA orienta hipóteses** e tomada de decisão.

4) Modelagem Preditiva (Aspectos Teóricos)

- Descreva o conceito de **aprendizado supervisionado**, diferenciando classificação e regressão.

- Explique **modelos clássicos** (Regressão Linear, Árvores, Redes Neurais, etc.) e suas vantagens/limitações.
- Aborde o conceito de **métricas de avaliação** (Accuracy, RMSE, R^2 , F1 etc.).
- Mencione **validação cruzada** e importância da reprodutibilidade.

5) Visualização e Comunicação dos Resultados

- Explique a importância de **dashboards, storytelling e relatórios visuais**.
- Descreva **boas práticas de comunicação de dados** (legibilidade, cores, acessibilidade).
- Mostre **modelos conceituais** de dashboards ou relatórios (pode usar figuras ou wireframes).
- Cite ferramentas como Looker Studio, Tableau, Power BI, Plotly.

6) Discussão e Reflexão Crítica

- Analise **os impactos éticos, sociais e econômicos** da ciência de dados.
- Discuta temas como:
 - Privacidade e LGPD
 - Viés algorítmico
 - Interpretação incorreta de métricas
 - Responsabilidade do cientista de dados
- Conclua relacionando o conceito de **“Do dado ao valor”** com tomada de decisão e geração de impacto.

Observação:

Os discentes, tem a liberdade de escolhas de ferramentas e das metodologias para solucionar o problema apresentado. Todas as mudanças devem serem justificadas, e repetir as boas práticas científicas, profissionais e a ética.

Todos os integrantes devem colaborar no seu Team. E, ao final, cada integrante deverá subir o produto final do grupo na sua sistematização para fins de avaliação.

No Trabalho deverá constar os nomes de todos os integrantes do Team.

Deverão atentar para a excelente apresentação do produto final.